



ΧΑΡΟΚΟΠΕΙΟ ΠΑΝΕΠΙΣΤΗΜΙΟ

Τμήμα Πληροφορικής και Τηλεματικής

Υπολογιστική Όραση

Σημασιολογική Τμηματοποίηση, Ανίχνευση Αντικειμένων
και Συγκριτική Αξιολόγηση Συνελικτικών Δικτύων vs Δικτύων Μετασχηματιστών

Τσιλιμπώκος Σπυρίδων - 25118

ΙΟΥΝΙΟΣ, ΑΘΗΝΑ 2026



Περιεχόμενα

1. Άσκηση 1 - Σημασιολογική Τμηματοποίηση (SBD).....	3
1.1 Σύνολο Δεδομένων SBD.....	3
1.2 Αρχιτεκτονική U-Net.....	3
1.3 Μετρικές Αξιολόγησης.....	4
1.4 Αποτελέσματα Πειραμάτων.....	4
Πείραμα 1: SBD Baseline.....	4
Πείραμα 2: SBD More Epochs.....	6
Πείραμα 3: SBD Larger Model.....	7
1.5 Συγκριτική Ανάλυση.....	8
1.6 Σχολιασμός Αποτελεσμάτων.....	8
2. Άσκηση 2 - Ανίχνευση Αντικειμένων / Τμηματοποίηση (Oxford-IIIT Pet).....	9
2.1 Σύνολο Δεδομένων Oxford-IIIT Pet.....	9
2.2 Αρχιτεκτονική.....	9
2.3 Αποτελέσματα Πειραμάτων.....	9
Πείραμα 1: PET Baseline.....	9
Πείραμα 2: PET More Epochs.....	11
Πείραμα 3: PET Larger Model.....	12
2.4 Συγκριτική Ανάλυση.....	13
2.5 Σχολιασμός Αποτελεσμάτων.....	13
3. Άσκηση 3 - Συγκριτική Αξιολόγηση CNN vs ViT (CIFAR-10).....	14
3.1 Σύνολο Δεδομένων CIFAR-10.....	14
3.2 Αρχιτεκτονική SmallCNN.....	14
3.3 Αρχιτεκτονική TinyViT.....	14
3.4 Μετρικές Αξιολόγησης.....	15
3.5 Πειράματα SmallCNN.....	15
CNN Πείραμα 1: Baseline.....	16
CNN Πείραμα 2: More Epochs.....	16
CNN Πείραμα 3: High Dropout.....	17
3.6 Πειράματα TinyViT.....	18
ViT Πείραμα 1: Baseline.....	18
ViT Πείραμα 2: More Epochs.....	19
ViT Πείραμα 3: Higher LR.....	20
3.7 Συγκριτική Ανάλυση CNN vs ViT.....	21
3.8 Σχολιασμός Αποτελεσμάτων.....	21
4. Γενικά Συμπεράσματα.....	22

1. Άσκηση 1 - Σημασιολογική Τμηματοποίηση (SBD)

Η πρώτη άσκηση αφορά την εφαρμογή σημασιολογικής τμηματοποίησης εικόνας στο σύνολο δεδομένων Semantic Boundaries Dataset (SBD), χρησιμοποιώντας αρχιτεκτονική U-Net. Στόχος είναι η πρόβλεψη της κλάσης PASCAL VOC για κάθε pixel μιας εικόνας, μεταξύ 21 κλάσεων (1 background και 20 κατηγορίες αντικειμένων). Πραγματοποιήθηκαν 3 πειράματα με διαφορετικές υπερ-παραμέτρους, αξιολογώντας την επίδρασή τους στην ακρίβεια τμηματοποίησης.

1.1 Σύνολο Δεδομένων SBD

Το Semantic Boundaries Dataset (SBD) διατίθεται μέσω του πακέτου torchvision ως torchvision.datasets.SBDataset, σε λειτουργία mode="segmentation". Κάθε δείγμα αποτελείται από μια φυσική εικόνα και μια αντίστοιχη μάσκα pixels όπου κάθε τιμή αντιστοιχεί σε μία από τις 21 κλάσεις PASCAL VOC (0 = background, 1-20 = κατηγορίες αντικειμένων).

Οι κλάσεις αντικειμένων καλύπτουν: αεροπλάνο, ποδήλατο, πουλί, βάρκα, μπουκάλι, λεωφορείο, αυτοκίνητο, γάτα, καρέκλα, αγελάδα, τραπέζι φαγητού, σκύλο, άλογο, μοτοσυκλέτα, άνθρωπο, φυτό σε γλάστρα, πρόβατο, καναπέ, τρένο και οθόνη τηλεόρασης/monitor. Λόγω περιορισμών υπολογιστικών πόρων (εκπαίδευση αποκλειστικά σε CPU), χρησιμοποιήθηκε υποσύνολο 600 εικόνων για εκπαίδευση και 200 για αξιολόγηση. Όλες οι εικόνες κλιμακώνονται σε 128x128 pixels πριν την εισαγωγή στο δίκτυο. Κατά την εκπαίδευση εφαρμόζεται τυχαία οριζόντια αναστροφή (πιθανότητα 50%) ως augmentation.

1.2 Αρχιτεκτονική U-Net

Η U-Net (Ronneberger et al., 2015) είναι αρχιτεκτονική encoder-decoder που σχεδιάστηκε για σημασιολογική τμηματοποίηση. Το βασικό της χαρακτηριστικό είναι οι skip connections, που μεταφέρουν χαρακτηριστικά χαμηλού επιπέδου (χωρικές λεπτομέρειες) από τον encoder στον αντίστοιχο decoder, επιτρέποντας ακριβή αποκατάσταση χωρικής πληροφορίας ενώ παράλληλα αξιοποιεί σημασιολογικό πλαίσιο από το bottleneck.

Κάθε convolutional block αποτελείται από δύο στρώματα Conv2d(3x3, padding=1) με BatchNormalization και ReLU ενεργοποίηση. Ο encoder εφαρμόζει MaxPool2d(2x2) για υποδειγματοληψία (downsampling) μεταξύ των επιπέδων. Ο decoder χρησιμοποιεί ConvTranspose2d(2x2, stride=2) για υπερδειγματοληψία (upsampling), ακολουθούμενο από concatenation με το αντίστοιχο skip connection από τον encoder και conv block για εξαγωγή χαρακτηριστικών. Το τελικό επίπεδο Conv2d(1x1) μετατρέπει τα χαρακτηριστικά σε logits για C=21 κλάσεις.

Στρώμα	Τύπος	Είσοδος	Έξοδος
Encoder 1	Conv Block + MaxPool	3	B
Encoder 2	Conv Block + MaxPool	B	2B
Encoder 3	Conv Block + MaxPool	2B	4B
Bottleneck	Conv Block	4B	8B
Decoder 3	ConvTranspose2d + concat + Conv Block	8B + 4B	4B
Decoder 2	ConvTranspose2d + concat + Conv Block	4B + 2B	2B
Decoder 1	ConvTranspose2d + concat + Conv Block	2B + B	B
Output	Conv2d(1x1)	B	C = 21

Πίνακας 1.1: Αρχιτεκτονική U-Net. B = αριθμός βασικών καναλιών (base channels).

Στα πειράματα χρησιμοποιούνται δύο τιμές για τον αριθμό βασικών καναλιών: B=16 για το ελαφρύτερο μοντέλο (στρώματα 16, 32, 64, 128 κανάλια) και B=32 για το μεγαλύτερο (32, 64, 128, 256 κανάλια).

1.3 Μετρικές Αξιολόγησης

Για την αξιολόγηση της απόδοσης τμηματοποίησης χρησιμοποιούνται δύο μετρικές: το mean Intersection over Union (mIoU) και η Pixel Accuracy (PA).

Το mIoU είναι η κύρια μετρική, που υπολογίζει για κάθε κλάση c τον λόγο τομής προς ένωση μεταξύ πρόβλεψης και ground truth, και λαμβάνει τον αριθμητικό μέσο μόνο για κλάσεις που εμφανίζονται στο batch:

$$mIoU = \frac{1}{C} \cdot \sum_{c=1}^C IoU(c)$$
$$IoU(c) = \frac{TP(c)}{TP(c) + FP(c) + FN(c)}$$

όπου TP(c) = αριθμός pixels που προβλέφθηκαν ορθά ως κλάση c, FP(c) = pixels άλλης κλάσης προβλεφθέντα ως c, FN(c) = pixels κλάσης c προβλεφθέντα ως άλλη κλάση.

Η Pixel Accuracy ορίζεται ως το ποσοστό των pixels που ταξινομήθηκαν ορθά συνολικά:

$$PA = \frac{\sum_{c=1}^C TP(c)}{N_{total}}$$

Η συνάρτηση απώλειας είναι η Cross-Entropy Loss για C κλάσεις:

$$L(\theta) = -\frac{1}{N} \cdot \sum_{i=1}^N \sum_{c=1}^C y(i,c) \cdot \log p(i,c)$$

όπου y(i,c) η ground truth one-hot ετικέτα, p(i,c) η πιθανότητα softmax για το pixel i και κλάση c, και θ οι παράμετροι του δικτύου. Η βελτιστοποίηση γίνεται με Adam optimizer και CosineAnnealingLR scheduler, ο οποίος μειώνει ομαλά τον ρυθμό εκμάθησης σύμφωνα με ημιτονοειδή καμπύλη από lr_max έως 0 σε T_max εποχές.

1.4 Αποτελέσματα Πειραμάτων

Πείραμα	Εποχές	lr	Base Ch.	mIoU (%)	Pixel Acc. (%)	Χρόνος (min)
SBD Exp1 - Baseline	5	1e-3	16	4.13	69.78	2.69
SBD Exp2 - More Epochs	10	5e-4	16	4.37	70.57	2.86
SBD Exp3 - Larger Model	5	1e-3	32	4.08	69.91	3.25


Πίνακας 1.2: Συνοπτικά αποτελέσματα και υπερ-παράμετροι 3 πειραμάτων SBD.

Πείραμα 1: SBD Baseline

Το baseline πείραμα χρησιμοποιεί 5 εποχές εκπαίδευσης, ρυθμό εκμάθησης lr = 0.001, και αριθμό βασικών καναλιών B=16. Επιτυγχάνεται mIoU = 4.13% και Pixel Accuracy = 69.78% σε χρόνο 2.69 λεπτά.


Οι καμπύλες εκπαίδευσης (Σχήμα 1.1) δείχνουν ταχεία μείωση της απώλειας στις πρώτες 2 εποχές (από 2.3 σε ~1.4) με σύγκλιση train/val, ακολουθούμενη από αργή πτώση σε plateau ~1.35. Η pixel accuracy (μέσο επίπεδο) συγκλίνει γρήγορα στο ~70%, ενώ το mIoU παρουσιάζει έντονες διακυμάνσεις (3.4-3.6%) χωρίς

σταθερή ανοδική τάση, γεγονός που αντανακλά την αδυναμία του δικτύου να μάθει ξεχωριστά κάθε μία από τις 21 κλάσεις με μόλις 600 δείγματα και 5 εποχές.



Σχήμα 1.1: Καμπύλες εκπαίδευσης Πειράματος 1 - SBD Baseline (Loss, Pixel Accuracy, Val mIoU ανά εποχή).

Τα δείγματα πρόβλεψης (Σχήμα 1.2) αποκαλύπτουν το βασικό πρόβλημα: το δίκτυο προβλέπει σχεδόν αποκλειστικά background (μαύρο) για όλα τα pixels, αγνοώντας τις επιμέρους σημασιολογικές κλάσεις. Αυτό εξηγεί γιατί η pixel accuracy φτάνει στο 70% (background κυριαρχεί ποσοτικά στις εικόνες) ενώ το mIoU παραμένει στο ~4% (όλες οι μη-background κλάσεις έχουν IoU ≈ 0).




Σχήμα 1.2: Ενδεικτικά αποτελέσματα τμηματοποίησης Πειράματος 1 - SBD Baseline (Εικόνα εισόδου, GT Mask με χρωματική παλέτα VOC, Προβλεπόμενη Mask).


Πείραμα 2: SBD More Epochs

Το δεύτερο πείραμα διπλασιάζει τις εποχές σε 10 και μειώνει τον ρυθμό εκμάθησης σε $lr = 0.0005$. Επιτυγχάνεται $mIoU = 4.37\%$ και $Pixel Accuracy = 70.57\%$, βελτίωση έναντι του baseline κατά 0.24 ποσοστιαίες μονάδες $mIoU$.

Οι καμπύλες (Σχήμα 1.3) παρουσιάζουν συνεχή μείωση απώλειας μέχρι την εποχή 10 (~1.25), με train και val να συγκλίνουν ομαλά, ενδεικτικό απουσίας overfitting. Η pixel accuracy φτάνει το 70-71%. Το $mIoU$ εξακολουθεί να ταλαντεύεται (3.4-4.2%) χωρίς σαφή τάση βελτίωσης, καθώς η θεμελιώδης δυσκολία (600 δείγματα, 21 κλάσεις) δεν αντιμετωπίζεται από μόνες τις επιπλέον εποχές. Η ελαφρά βελτίωση οφείλεται κυρίως στον μικρότερο ρυθμό εκμάθησης που επιτρέπει πιο λεπτή βελτιστοποίηση.



Σχήμα 1.3: Καμπύλες εκπαίδευσης Πειράματος 2 - SBD More Epochs (10 εποχές, $lr=5e-4$, $B=16$).




Σχήμα 1.4: Αποτελέσματα τμηματοποίησης Πειράματος 2 - SBD More Epochs.


Πείραμα 3: SBD Larger Model

Το τρίτο πείραμα διπλασιάζει τον αριθμό βασικών καναλιών σε $B=32$, διατηρώντας 5 εποχές και $lr=1e-3$. Επιτυγχάνεται $mIoU = 4.08\%$ και $Pixel Accuracy = 69.91\%$. Ο χρόνος εκπαίδευσης αυξάνεται σε 3.25 λεπτά λόγω των επιπλέον παραμέτρων.

Αξιοσημείωτο είναι ότι το μεγαλύτερο μοντέλο δεν αποδίδει καλύτερα από το baseline ($mIoU 4.08\%$ vs 4.13%). Τα δείγματα πρόβλεψης (Σχήμα 1.6) αποκαλύπτουν μια ελαφρά καλύτερη κατάσταση: εμφανίζονται ορισμένες έγχρωμες περιοχές στις προβλέψεις (π.χ. ροζ για την κλάση "person"), γεγονός που δεν παρατηρείται στα μικρότερα μοντέλα. Αυτό υποδηλώνει ότι το μεγαλύτερο μοντέλο αρχίζει να αναγνωρίζει περισσότερες κλάσεις, αλλά 5 εποχές δεν επαρκούν για ουσιαστική σύγκλιση.




Σχήμα 1.5: Καμπύλες εκπαίδευσης Πειράματος 3 - SBD Larger Model (5 εποχές, $lr=1e-3$, $B=32$).



Σχήμα 1.6: Αποτελέσματα τμηματοποίησης Πειράματος 3 - SBD Larger Model. Παρατηρούνται ελαφρώς περισσότερες έγχρωμες περιοχές στις προβλέψεις συγκριτικά με τα μικρότερα μοντέλα.

1.5 Συγκριτική Ανάλυση



Σχήμα 1.7: Σύγκριση mIoU (%) μεταξύ των 3 πειραμάτων SBD.

Και τα 3 πειράματα αποδίδουν mIoU στην περιοχή 4.08-4.37%, με πολύ μικρές διαφορές (< 0.3 ποσοστιαίες μονάδες). Η pixel accuracy κυμαίνεται σε 69.78-70.57%. Το καλύτερο mIoU επιτυγχάνεται από το Exp2 (4.37%) λόγω περισσότερων εποχών και μικρότερου lr που επιτρέπει πιο ακριβή βελτιστοποίηση. Η βελτίωση έναντι του baseline είναι ελάχιστη, γεγονός που επιβεβαιώνει ότι ο κύριος περιοριστικός παράγοντας δεν είναι οι υπερ-παραμέτροι αλλά η θεμελιώδης δυσκολία του προβλήματος στις δεδομένες συνθήκες.

1.6 Σχολιασμός Αποτελεσμάτων

Τα αποτελέσματα mIoU 4-4.4% φαίνονται εκ πρώτης όψεως χαμηλά, αλλά είναι απολύτως αναμενόμενα και εξηγήσιμα από τους ακόλουθους λόγους:

(α) Ανεπαρκής αριθμός δεδομένων: Με μόλις 600 δείγματα εκπαίδευσης για 21 κλάσεις, κάθε κλάση αντιστοιχεί κατά μέσο όρο σε ~30 εικόνες μόνο. Κλάσεις που εμφανίζονται σπάνια (π.χ. βάρκα, πρόβατο) έχουν $\text{IoU} \approx 0$, ρίχνοντας δραματικά τον μέσο όρο. (β) Ανισορροπία κλάσεων: Το background κυριαρχεί ποσοτικά (~80-90% των pixels σε πολλές εικόνες). Το δίκτυο μαθαίνει γρήγορα να προβλέπει background παντού, εξηγώντας την υψηλή pixel accuracy (~70%) παρά τη χαμηλή mIoU. (γ) Επεξεργασία CPU: Τα 5-10 epochs με υποσύνολο 600 δειγμάτων στα 128x128 δεν αρκούν για σύγκλιση σε 21-κλάσεων segmentation. Σε GPU με πλήρες σύνολο δεδομένων (~10.000 εικόνες) και 100+ εποχές, η U-Net επιτυγχάνει mIoU $>30\%$ στο SBD. Συμπερασματικά, η αρχιτεκτονική λειτουργεί ορθά, ο περιοριστικός παράγοντας είναι το μέγεθος δεδομένων και υπολογιστικοί πόροι.

2. Άσκηση 2 - Ανίχνευση Αντικειμένων / Τμηματοποίηση (Oxford-IIIT Pet)

Η δεύτερη άσκηση αφορά την ανίχνευση και τμηματοποίηση αντικειμένων στο σύνολο δεδομένων Oxford-IIIT Pet, με χρήση της αρχιτεκτονικής U-Net. Χρησιμοποιούνται trimap annotations που διαχωρίζουν κάθε εικόνα σε 3 κλάσεις: foreground (κατοικίδιο), background, και boundary (περίγραμμα). Πραγματοποιήθηκαν 3 πειράματα με διαφορετικές υπερ-παραμέτρους.

2.1 Σύνολο Δεδομένων Oxford-IIIT Pet

Το Oxford-IIIT Pet Dataset περιέχει φωτογραφίες κατοικίδιων ζώων (σκύλοι και γάτες, 37 φυλές) με ακριβείς trimap annotations. Κάθε trimap αποτελείται από pixels τριών τιμών: 1 (foreground/ζώο), 2 (background), 3 (boundary/αμφίβολη περιοχή περιγράμματος). Στην υλοποίηση γίνεται αντιστοίχιση: 1→0 (foreground), 2→1 (background), 3→2 (boundary), δημιουργώντας 3 κλάσεις για Cross-Entropy Loss. Χρησιμοποιήθηκε υποσύνολο 1200 εικόνων για εκπαίδευση και 300 για αξιολόγηση, με αναδιαμόρφωση σε 128x128 pixels.

Η χρωματική κωδικοποίηση των masks είναι: κόκκινο για foreground (σώμα ζώου), πράσινο για background, και μπλε για boundary (λεπτή ζώνη μετάβασης). Το boundary class είναι η πιο δύσκολη κλάση λόγω του μικρού της πλήθους pixels και της ασαφούς φύσης του.

2.2 Αρχιτεκτονική

Χρησιμοποιείται η ίδια U-Net με την Άσκηση 1, προσαρμοσμένη για C=3 κλάσεις στο τελικό επίπεδο (έναντι 21 για το SBD). Η εκπαίδευση ωφελείται σημαντικά από το μικρό πλήθος κλάσεων, καθώς ο κάθε optimizer step λαμβάνει πολύ πιο πληροφοριακό gradient σήμα. Επίσης, ο λόγος foreground/background είναι πολύ πιο ισορροπημένος από ό,τι στο SBD, αφού κάθε εικόνα περιέχει ουσιαστικά ένα ζώο.

2.3 Αποτελέσματα Πειραμάτων


Πείραμα	Εποχές	lr	Base Ch.	mIoU (%)	Pixel Acc. (%)	Χρόνος (min)
PET Exp1 - Baseline	5	1e-3	16	61.28	83.70	4.30
PET Exp2 - More Epochs	10	5e-4	16	64.63	85.68	4.66
PET Exp3 - Larger Model	5	1e-3	32	58.80	82.75	5.99

Πίνακας 2.1: Αποτελέσματα και υπερ-παραμέτροι 3 πειραμάτων Oxford-IIIT Pet.

Πείραμα 1: PET Baseline

Το baseline πείραμα με 5 εποχές και lr=1e-3 επιτυγχάνει mIoU = 61.28% και Pixel Accuracy = 83.70%. Τα αποτελέσματα αυτά είναι ήδη σημαντικά υψηλότερα από την Άσκηση 1, αντικατοπτρίζοντας την απλούστερη φύση του προβλήματος (3 κλάσεις, 1200 δείγματα).

Οι καμπύλες (Σχήμα 2.1) δείχνουν ότι η απώλεια μειώνεται ομαλά από 0.75 σε ~0.44 στις 5 εποχές, με train και val να παραμένουν σχεδόν ταυτόσημα - απουσία overfitting. Το mIoU ανεβαίνει συνεχώς κατά τη διάρκεια εκπαίδευσης και φτάνει ~62% στην εποχή 5, με σαφή ανοδική τάση που δηλώνει ότι το μοντέλο θα συνέχιζε να βελτιώνεται με περισσότερες εποχές.



Σχήμα 2.1: Καμπύλες εκπαίδευσης Πειράματος 1 - PET Baseline (5 εποχές, $lr=1e-3$, $B=16$).

Τα δείγματα τμηματοποίησης (Σχήμα 2.2) αποκαλύπτουν ότι το μοντέλο αναγνωρίζει ορθά το σχήμα του ζώου (κόκκινη περιοχή foreground) και διαχωρίζει αποτελεσματικά background (πράσινο). Η κύρια αδυναμία εντοπίζεται στο boundary class (μπλε λεπτό περίγραμμα), που αποδίδεται λιγότερο ακριβώς. Για το σκύλο με παιχνίδια (πρώτη σειρά), παρατηρείται ότι ορισμένα αντικείμενα background κοντά στο ζώο ταξινομούνται λανθασμένα ως foreground.




Σχήμα 2.2: Αποτελέσματα τμηματοποίησης Πειράματος 1 - PET Baseline (κόκκινο=foreground, πράσινο=background, μπλε=boundary).

Πείραμα 2: PET More Epochs


Το δεύτερο πείραμα διπλασιάζει τις εποχές σε 10 και μειώνει τον ρυθμό εκμάθησης σε $lr = 0.0005$. Επιτυγχάνεται το καλύτερο mIoU = 64.63% και Pixel Accuracy = 85.68%, βελτίωση κατά 3.35 ποσοστιαίες μονάδες mIoU έναντι του baseline.

Οι καμπύλες (Σχήμα 2.3) είναι ιδιαίτερα εντυπωσιακές: η απώλεια μειώνεται ομαλά από 0.75 σε ~0.36, με train και val να παραμένουν σχεδόν ταυτόσημα σε όλες τις 10 εποχές, επιβεβαίωση της απουσίας overfitting. Η pixel accuracy αγγίζει το 85.68%, ενώ το val mIoU ανεβαίνει συνεχώς από ~42% στην εποχή 1 σε ~65% στην εποχή 10, με ακόμα ανοδική τάση, γεγονός που δηλώνει ότι περαιτέρω εκπαίδευση θα βελτιώνει τα αποτελέσματα.



Σχήμα 2.3: Καμπύλες εκπαίδευσης Πειράματος 2 - PET More Epochs (10 εποχές, $lr=5e-4$, $B=16$). Σημειώνεται η άριστη σύγκλιση train/val χωρίς overfitting.

Τα δείγματα πρόβλεψης (Σχήμα 2.4) είναι εμφανώς καλύτερα από το Exp1: τα σχήματα των ζώων αποδίδονται με μεγαλύτερη ακρίβεια, η διαχωριστική γραμμή foreground/background είναι πιο καθαρή. Το boundary class εξακολουθεί να παρουσιάζει δυσκολίες (αναμενόμενο λόγω μικρού πλήθους pixels), αλλά είναι εμφανές σε περισσότερες περιπτώσεις. Συνολικά η οπτική ποιότητα του segmentation είναι πολύ ικανοποιητική για CPU-only εκπαίδευση σε 128x128 pixels.




Σχήμα 2.4: Αποτελέσματα τμηματοποίησης Πειράματος 2 - PET More Epochs. Παρατηρείται βελτιωμένη ακρίβεια ορίων και καθαρότερος διαχωρισμός foreground/background.


Πείραμα 3: PET Larger Model

Το τρίτο πείραμα χρησιμοποιεί $B=32$ (μεγαλύτερο μοντέλο) με 5 εποχές και $lr=1e-3$. Επιτυγχάνεται $mIoU = 58.80\%$ και $Pixel Accuracy = 82.75\%$, αποτέλεσμα χαμηλότερο τόσο από το baseline όσο και από το Exp2. Ο χρόνος εκπαίδευσης αυξάνεται σε 5.99 λεπτά.

Οι καμπύλες (Σχήμα 2.5) δείχνουν ότι το μεγαλύτερο μοντέλο συγκλίνει με παρόμοιο ρυθμό με το Exp1, αλλά η pixel accuracy παρουσιάζει αστάθεια στις εποχές 2-3 (dip ορατό στο γράφημα) πριν ανακάμψει. Το $mIoU$ ανεβαίνει ομαλά αλλά φτάνει μόλις $\sim 58\%$ στις 5 εποχές. Η αδυναμία του μεγαλύτερου μοντέλου οφείλεται στον μεγαλύτερο αριθμό παραμέτρων που χρειάζεται περισσότερες εποχές για να βελτιστοποιηθεί. Με 10 εποχές (όπως στο Exp2), το $B=32$ μοντέλο πιθανώς θα ξεπερνούσε το $B=16$.




Σχήμα 2.5: Καμπύλες εκπαίδευσης Πειράματος 3 - PET Larger Model (5 εποχές, $lr=1e-3$, $B=32$).



Σχήμα 2.6: Αποτελέσματα τμηματοποίησης Πειράματος 3 - PET Larger Model. Το segmentation είναι λειτουργικό αλλά ελαφρώς ακατέργαστο λόγω ανεπαρκών εποχών για το μεγαλύτερο μοντέλο.

2.4 Συγκριτική Ανάλυση



Σχήμα 2.7: Σύγκριση mIoU (%) μεταξύ των 3 πειραμάτων Oxford-IIIT Pet.

Από τα 3 πειράματα, το Exp2 (More Epochs) επιτυγχάνει το καλύτερο mIoU (64.63%), ακολουθούμενο από το Exp1 Baseline (61.28%) και το Exp3 Larger Model (58.80%). Το εύρος των αποτελεσμάτων (58.8-64.6%) δηλώνει ότι τα αποτελέσματα είναι συνεπή και αξιόπιστα.

Το βασικό συμπέρασμα είναι ότι η αύξηση εποχών με ταυτόχρονη μείωση lr (Exp2) αποδίδει καλύτερα από την αύξηση της χωρητικότητας μοντέλου (Exp3) στις δεδομένες συνθήκες. Αυτό είναι αναμενόμενο: με 1200 δείγματα, το B=16 U-Net δεν underfits - έχει επαρκή χωρητικότητα για το πρόβλημα. Η αδυναμία βρίσκεται στη συνολική ποσότητα εκπαίδευσης (compute budget), όχι στο μέγεθος μοντέλου.

2.5 Σχολιασμός Αποτελεσμάτων

Τα αποτελέσματα της Άσκησης 2 είναι σημαντικά καλύτερα από την Άσκηση 1, με καλύτερο mIoU 64.6%, έναντι 4.4% για το SBD. Οι κύριοι λόγοι είναι:

(α) Μόλις 3 κλάσεις έναντι 21 στο SBD: Κάθε κλάση εκπροσωπείται επαρκώς σε κάθε εικόνα, δίνοντας ισχυρό gradient signal. (β) Ισορροπημένη κατανομή κλάσεων: Κάθε εικόνα περιέχει ουσιαστικά ένα ζώο, οπότε foreground/background/boundary εκπροσωπούνται σε εύλογες αναλογίες. (γ) Εννοιολογική απλότητα: Το πρόβλημα αναγωγής ζώου/background είναι απλούστερο από σημασιολογική τμηματοποίηση 21 κλάσεων. Εν ολίγοις, η U-Net αποδεικνύεται ιδιαίτερα κατάλληλη για binary/trimap segmentation tasks, επιτυγχάνοντας σημαντική ακρίβεια ακόμα και με περιορισμένους υπολογιστικούς πόρους.

3. Άσκηση 3 - Συγκριτική Αξιολόγηση CNN vs ViT (CIFAR-10)

Η τρίτη άσκηση πραγματοποιεί συγκριτική αξιολόγηση δύο διαφορετικών αρχιτεκτονικών βαθιάς μάθησης στο σύνολο δεδομένων CIFAR-10: ενός Συνελικτικού Νευρωνικού Δικτύου (SmallCNN) και ενός Δικτύου Μετασχηματιστών (TinyViT). Πραγματοποιήθηκαν 3 πειράματα για κάθε αρχιτεκτονική, συνολικά 6 πειράματα, αξιολογώντας τον ρόλο εποχών εκπαίδευσης, ρυθμού εκμάθησης και παραμέτρου dropout.

3.1 Σύνολο Δεδομένων CIFAR-10

Το CIFAR-10 αποτελείται από 60.000 έγχρωμες εικόνες 32x32 pixels (50.000 για εκπαίδευση, 10.000 για αξιολόγηση) κατανεμημένες ισόποσα σε 10 κλάσεις: airplane, automobile, bird, cat, deer, dog, frog, horse, ship, truck. Για λόγους υπολογιστικής αποδοτικότητας σε CPU, χρησιμοποιήθηκε υποσύνολο 5000 εικόνων για εκπαίδευση και 1000 για αξιολόγηση (τυχαία επιλογή με τυχαία καταστατημένο seed=42 για αναπαραγωγικότητα).

Προεπεξεργασία: Κανονικοποίηση με mean=(0.4914, 0.4822, 0.4465) και std=(0.2470, 0.2435, 0.2616). Κατά την εκπαίδευση εφαρμόζονται augmentations: τυχαία αποκοπή 32x32 με padding=4 και τυχαία οριζόντια αναστροφή.

3.2 Αρχιτεκτονική SmallCNN

Το SmallCNN αποτελείται από 3 convolutional blocks ακολουθούμενα από fully-connected head. Κάθε block αποτελείται από Conv2d(3x3) με BatchNorm, ReLU ενεργοποίηση και MaxPool2d(2x2). Το head αποτελείται από Flatten, Linear(128x4x4 -> 256), ReLU, Dropout(p) και Linear(256 -> 10). Τα κανάλια αυξάνονται προοδευτικά: 3 -> 32 -> 64 -> 128.

Στρώμα	Τύπος	Παράμετροι
Conv Block 1	Conv2d(3,32,3) + BN + ReLU + MaxPool(2)	896 + 64
Conv Block 2	Conv2d(32,64,3) + BN + ReLU + MaxPool(2)	18.496 + 128
Conv Block 3	Conv2d(64,128,3) + BN + ReLU + MaxPool(2)	73.856 + 256
Flatten	Reshape (128 x 4 x 4 = 2048)	-
FC1	Linear(2048 -> 256) + ReLU + Dropout(p)	524.288 + 256
FC2	Linear(256 -> 10)	2.570

Πίνακας 3.1: Αρχιτεκτονική SmallCNN για ταξινόμηση CIFAR-10 (p = dropout ratio).

3.3 Αρχιτεκτονική TinyViT

Το TinyViT (Vision Transformer) χρησιμοποιεί αρχιτεκτονική μετασχηματιστή για ταξινόμηση εικόνων, χωρίς inductive bias συνέλιξης. Η αρχιτεκτονική ακολουθεί τα εξής βήματα:

(α) Patch Embedding: Η εικόνα 32x32 διαιρείται σε patches 4x4, παράγοντας $N = \left(\frac{32}{4}\right)^2 = 64$ patches. Κάθε patch προβάλλεται σε embedding διαστάσεων $D=64$ μέσω Conv2d(3, 64, kernel=4, stride=4). (β) CLS Token: Προστίθεται ένα εκπαιδευσιμο [CLS] token, οπότε η ακολουθία έχει μήκος $N+1=65$. (γ) Positional Embedding: Προστίθεται εκπαιδευσιμο positional embedding σε κάθε στοιχείο της ακολουθίας: $x = \text{PatchEmbed}(\text{img}) + \text{pos_embed}$. (δ) Transformer Encoder: 4 στρώματα TransformerEncoderLayer με 4 attention heads, feedforward dim = 256, dropout=0.1 και norm_first=True (Pre-LN αρχιτεκτονική). (ε) Head: LayerNorm εφαρμόζεται στο [CLS] token εξόδου, ακολουθούμενο από Linear(64 -> 10) για ταξινόμηση.



Στρώμα	Τύπος	Διάσταση εξόδου
Patch Embed	Conv2d(3,64,k=4,s=4) -> flatten	(B, 64, D=64)
CLS Token	Learnable parameter (1,1,64)	(B, 65, 64)
+ Pos. Embed	Learnable parameter (1,65,64)	(B, 65, 64)
TransformerLayer x4	MultiHeadAttn(4h) + FFN(256) + LayerNorm	(B, 65, 64)
LayerNorm	LayerNorm(64) on CLS token	(B, 64)
Head	Linear(64 -> 10)	(B, 10)

Πίνακας 3.2: Αρχιτεκτονική TinyViT. B = batch size, D = embedding dimension.

Η βασική διαφορά CNN vs ViT είναι ότι η CNN έχει inductive bias τοπικής συνδεσιμότητας (local connectivity) και μεταθετικής αναλλοίωτης ισοδυναμίας (translation equivariance), ενώ το ViT μαθαίνει αυτές τις ιδιότητες από τα δεδομένα μέσω attention. Αυτό σημαίνει ότι τα ViT χρειάζονται πολύ περισσότερα δεδομένα για να αποδώσουν συγκρίσιμα με CNN.

3.4 Μετρικές Αξιολόγησης

Για την ταξινόμηση χρησιμοποιείται η Top-1 Accuracy (ποσοστό εικόνων που ταξινομήθηκαν στη σωστή κλάση):

$$Accuracy = \frac{1}{N} \cdot \sum_{i=1}^N \mathbb{1}[\arg\max f(x_i, \theta) = y_i]$$

όπου $f(x_i, \theta)$ το vector logits και y_i η ετικέτα κλάσης. Η Cross-Entropy Loss για $C=10$ κλάσεις:

$$L(\theta) = -\frac{1}{N} \cdot \sum_{i=1}^N \log p(i, y_i)$$

όπου η softmax πιθανότητα $p(i, c)$ ορίζεται ως:

$$p(i, c) = \frac{\exp(z(i, c))}{\sum_{k=1}^C \exp(z(i, k))}$$

και $z(i, c)$ τα logits (έξοδος δικτύου πριν softmax) για pixel/δείγμα i και κλάση c .


3.5 Πειράματα SmallCNN

Πείραμα	Εποχές	lr	Dropout	Val Acc (%) - Max	Val Acc (%) - Final	Χρόνος (min)
CNN Exp1 - Baseline	10	1e-3	0.3	57.70	57.10	0.62
CNN Exp2 - More Epochs	20	5e-4	0.3	66.10	65.80	1.10
CNN Exp3 - High Dropout	10	1e-3	0.5	52.50	52.00	0.55


Πίνακας 3.3: Αποτελέσματα SmallCNN ανά πείραμα στο CIFAR-10.

CNN Πείραμα 1: Baseline

Το baseline πείραμα με 10 εποχές, $lr=1e-3$ και $dropout=0.3$ επιτυγχάνει Val Accuracy = 57.70%. Οι καμπύλες (Σχήμα 3.1) δείχνουν ομαλή σύγκλιση: η απώλεια μειώνεται από ~2.0 σε ~1.2 και η ακρίβεια αυξάνεται από ~28% σε ~57%. Train και validation παραμένουν πολύ κοντά σε όλες τις εποχές, υποδηλώνοντας ελάχιστο overfitting. Το μοντέλο φαίνεται να μπορεί να βελτιωθεί περαιτέρω με περισσότερες εποχές.



Σχήμα 3.1: Καμπύλες εκπαίδευσης CNN Πείραμα 1 - Baseline (10 εποχές, $lr=1e-3$, $dropout=0.3$).




Σχήμα 3.2: Δείγματα ταξινόμησης CNN Πείραμα 1 (πράσινο = ορθή πρόβλεψη, κόκκινο = λανθασμένη).

CNN Πείραμα 2: More Epochs

Το δεύτερο πείραμα διπλασιάζει τις εποχές σε 20 και μειώνει $lr=5e-4$. Επιτυγχάνεται Val Accuracy = 66.10%, βελτίωση 8.40 ποσοστιαίων μονάδων έναντι baseline. Αυτό είναι το καλύτερο αποτέλεσμα CNN.

Οι καμπύλες (Σχήμα 3.3) δείχνουν συνεχή βελτίωση και στις 20 εποχές, με ελαφρά απόκλιση train/val στις τελευταίες εποχές (train ~68%, val ~66%) που υποδηλώνει ήπιο overfitting. Η απώλεια val συνεχίζει να μειώνεται και στην εποχή 20, γεγονός που δηλώνει ότι το μοντέλο θα βελτιωνόταν περαιτέρω με επιπλέον εκπαίδευση.



Σχήμα 3.3: Καμπύλες εκπαίδευσης CNN Πείραμα 2 - More Epochs (20 εποχές, $lr=5e-4$, dropout=0.3). Παρατηρείται ελαφρά απόκλιση train/val στις τελευταίες εποχές.

Τα δείγματα ταξινόμησης (Σχήμα 3.4) αποδεικνύουν ιδιαίτερα καλή αναγνώριση οχημάτων (automobile, truck, ship) ενώ η σύγχυση παρατηρείται κυρίως σε ζώα με παρόμοια χαρακτηριστικά (cat/dog, bird/ship σε χαμηλή ανάλυση).




Σχήμα 3.4: Δείγματα ταξινόμησης CNN Πείραμα 2 - More Epochs. Τα οχήματα ταξινομούνται με υψηλή ακρίβεια.

CNN Πείραμα 3: High Dropout

Το τρίτο πείραμα αυξάνει το dropout σε $p=0.5$ (από 0.3) με 10 εποχές και $lr=1e-3$. Επιτυγχάνεται Val Accuracy = 52.50%, το χαμηλότερο μεταξύ των CNN πειραμάτων.

Ιδιαίτερο χαρακτηριστικό (Σχήμα 3.5): κατά τις πρώτες εποχές, η val accuracy ξεπερνά την train accuracy. Αυτό είναι αναμενόμενο με υψηλό dropout: κατά το training, τυχαία 50% των νευρώνων απενεργοποιούνται, μειώνοντας αποτελεσματικά τη χωρητικότητα του δικτύου. Κατά την αξιολόγηση, όλοι οι νευρώνες ενεργοποιούνται (με scaling), δίνοντας πλεονέκτημα. Το υψηλό dropout (0.5) αποδεικνύεται υπερβολικό regularization για αυτό το μοντέλο: παρεμποδίζει την εκπαίδευση περισσότερο από ό,τι ωφελεί στη γενίκευση, οδηγώντας σε χαμηλότερη τελική ακρίβεια.



Σχήμα 3.5: Καμπύλες εκπαίδευσης CNN Πείραμα 3 - High Dropout (10 εποχές, $lr=1e-3$, dropout=0.5). Σημειώνεται το φαινόμενο val accuracy > train accuracy στις πρώτες εποχές λόγω dropout.



Σχήμα 3.6: Δείγματα ταξινόμησης CNN Πείραμα 3 - High Dropout.

3.6 Πειράματα TinyViT


Πείραμα	Εποχές	lr	Dropout	Val Acc (%) - Max	Val Acc (%) - Final	Χρόνος (min)
ViT Exp1- Baseline	10	1e-3	0.1	40.10	40.00	2.22
ViT Exp2 - More Epochs	20	5e-4	0.1	47.10	46.10	4.49
ViT Exp3 - Higher LR	10	2e-3	0.1	40.70	40.70	2.07

Πίνακας 3.4: Αποτελέσματα TinyViT ανά πείραμα στο CIFAR-10.

ViT Πείραμα 1: Baseline

Το baseline ViT με 10 εποχές, $lr=1e-3$ και dropout=0.1 επιτυγχάνει Val Accuracy = 40.10%, σημαντικά χαμηλότερα από το CNN baseline (57.70%).

Οι καμπύλες (Σχήμα 3.7) δείχνουν αργή σύγκλιση: η απώλεια μειώνεται από ~2.1 σε ~1.6 (έναντι 2.0->1.2 για CNN). Μετά την εποχή 7, παρατηρείται αρχή απόκλισης train/val (ήπιο overfitting), ενώ η καμπύλη val accuracy παρουσιάζει πλατό στο ~42%. Ο μετασχηματιστής αδυνατεί να εκμεταλλευτεί τη δομή 32x32 εικόνων με μόλις 5000 δείγματα, καθώς δεν διαθέτει inductive bias.



Σχήμα 3.7: Καμπύλες εκπαίδευσης ViT Πείραμα 1 - Baseline (10 εποχές, $lr=1e-3$, dropout=0.1).




Σχήμα 3.8: Δείγματα ταξινόμησης ViT Πείραμα 1 - Baseline. Παρατηρούνται περισσότερα σφάλματα συγκριτικά με το CNN.


ViT Πείραμα 2: More Epochs

Με 20 εποχές και $lr=5e-4$, το ViT επιτυγχάνει Val Accuracy = 47.10%, βελτίωση 7.00 ποσοστιαίων μονάδων. Αυτό είναι το καλύτερο αποτέλεσμα ViT.

Οι καμπύλες (Σχήμα 3.9) δείχνουν ότι η απόδοση του ViT βελτιώνεται σταθερά με περισσότερες εποχές. Η απώλεια val παραμένει σχεδόν ίδια με την train loss (1.53 vs 1.45 στην εποχή 20), αλλά η train accuracy ξεπερνά σαφώς την val accuracy (~47% train vs 47% val), δείχνοντας ότι το μοντέλο αρχίζει να απομνημονεύει. Αξιοσημείωτο: και στην εποχή 20, το val mIoU εξακολουθεί να ανεβαίνει αργά - το ViT χρειάζεται πολύ περισσότερες εποχές για να αξιοποιήσει πλήρως την αρχιτεκτονική του.



Σχήμα 3.9: Καμπύλες εκπαίδευσης ViT Πείραμα 2 - More Epochs (20 εποχές, $lr=5e-4$, dropout=0.1).




Σχήμα 3.10: Δείγματα ταξινόμησης ViT Πείραμα 2 - More Epochs. Σαφώς περισσότερα σφάλματα από τα αντίστοιχα CNN δείγματα.

ViT Πείραμα 3: Higher LR

Το τρίτο πείραμα αυξάνει τον ρυθμό εκμάθησης σε $lr=2e-3$ (10 εποχές, dropout=0.1). Επιτυγχάνεται Val Accuracy = 40.70%, το χαμηλότερο μεταξύ των ViT πειραμάτων.

Οι καμπύλες (Σχήμα 3.11) αποκαλύπτουν αστάθεια λόγω του υψηλού lr: εμφανίζεται εμφανής αύξηση/μείωση της val accuracy γύρω από την εποχή 8. Ο υψηλός ρυθμός εκμάθησης αναγκάζει τον optimizer να κάνει μεγάλα βήματα που ξεφεύγουν από τοπικά ελάχιστα. Για μετασχηματιστές, το lr πρέπει να επιλέγεται με μεγάλη προσοχή - τυπικά είναι μικρότερο από ό,τι για CNN λόγω της πολυπλοκότητας του loss landscape.




Σχήμα 3.11: Καμπύλες εκπαίδευσης ViT Πείραμα 3 - Higher LR (10 εποχές, $lr=2e-3$, dropout=0.1). Παρατηρείται αστάθεια κατά την εκπαίδευση λόγω υψηλού ρυθμού εκμάθησης.



Σχήμα 3.12: Δείγματα ταξινόμησης ViT Πείραμα 3 - Higher LR.

3.7 Συγκριτική Ανάλυση CNN vs ViT



Σχήμα 3.13: Σύγκριση Val Accuracy (%) SmallCNN vs TinyViT σε 6 πειράματα CIFAR-10.

Μετρική	SmallCNN (καλύτερο)	TinyViT (καλύτερο)	Διαφορά
Val Accuracy (max)	66.10%	47.10%	19.00 μον.
Βέλτιστο πείραμα	Exp2: 20ep, lr=5e-4	Exp2: 20ep, lr=5e-4	-
Χρόνος εκπαίδευσης (best)	1.10 min	4.49 min	x4.1 αργότερο ViT
Overfitting	Ήπιο (Exp2: ~2%)	Ήπιο-Μέτριο	-
Αστάθεια σε υψηλό lr	Όχι	Ναι (Exp3)	-

Πίνακας 3.5: Συγκριτική ανάλυση SmallCNN vs TinyViT.

3.8 Σχολιασμός Αποτελεσμάτων

Το SmallCNN υπερτερεί σαφώς του TinyViT σε όλα τα πειράματα, με διαφορά ακρίβειας 19.0 ποσοστιαίες μονάδες στα βέλτιστα πειράματα. Επιπλέον, το CNN εκπαιδεύεται 4.1x πιο γρήγορα από το ViT για ίδιο αριθμό εποχών. Αυτά τα αποτελέσματα συνάδουν απόλυτα με τη θεωρία:

(α) Inductive bias CNN: Τα CNN εκμεταλλεύονται τη χωρική δομή των εικόνων μέσω τοπικής συνδεσιμότητας και weight sharing, μαθαίνοντας αποτελεσματικά από λίγα δείγματα. (β) Data hunger ViT: Τα ViT μαθαίνουν τη χωρική δομή αποκλειστικά από τα δεδομένα μέσω self-attention, χωρίς κανένα inductive bias. Χρειάζονται εκατομμύρια δείγματα εκπαίδευσης (π.χ. ImageNet-21k) για να ξεπεράσουν τα CNN. Με 5000 δείγματα, το TinyViT αδυνατεί να μάθει αξιόπιστες αναπαραστάσεις. (γ) Μέγεθος patch vs ανάλυση: Ο patch size=4 σε εικόνες 32x32 δίνει μόλις 64 patches, περιορίζοντας την ανάλυση. Για μεγαλύτερες εικόνες (224x224) το ViT θα είχε 3136 patches με πολύ πλουσιότερη αναπαράσταση. (δ) Υπολογιστικό κόστος: Η πολυπλοκότητα του self-attention είναι $O(N^2)$ ως προς τον αριθμό patches N , καθιστώντας το ViT αισθητά πιο αργό. Συμπερασματικά, για μικρά datasets και περιορισμένο compute, οι CNN αρχιτεκτονικές παραμένουν η βέλτιστη επιλογή. Τα ViT αποδίδουν καλύτερα μόνο με massive pre-training ή μεγάλα domain-specific datasets.

4. Γενικά Συμπεράσματα

Η εργασία υλοποίησε και αξιολόγησε μεθόδους σημασιολογικής τμηματοποίησης, ανίχνευσης αντικειμένων και ταξινόμησης εικόνων με χρήση βαθιών νευρωνικών δικτύων σε περιβάλλον CPU. Τα κύρια ευρήματα συνοψίζονται ως εξής:

Άσκηση	Αρχιτεκτονική	Dataset	Βέλτιστο mIoU/Acc	Βέλτιστο Πείραμα
1 - SBD	U-Net (B=16)	SBD 21 κλ., 600/200	4.37% mIoU	Exp2 (10ep, lr=5e-4)
2 - Pet	U-Net (B=16)	Pet 3 κλ., 1200/300	64.63% mIoU	Exp2 (10ep, lr=5e-4)
3 - CIFAR CNN	SmallCNN	CIFAR-10, 5000/1000	66.10% Acc	Exp2 (20ep, lr=5e-4)
3 - CIFAR ViT	TinyViT	CIFAR-10, 5000/1000	47.10% Acc	Exp2 (20ep, lr=5e-4)

Πίνακας 4.1: Συνολική σύγκριση βέλτιστων αποτελεσμάτων ανά άσκηση.

(α) Κοινό συμπέρασμα και στις 3 ασκήσεις: Η αύξηση εποχών εκπαίδευσης με ταυτόχρονη μείωση lr (Exp2 σε κάθε άσκηση) αποδίδει σταθερά καλύτερα από άλλες αλλαγές (μεγαλύτερο μοντέλο, υψηλότερο dropout, υψηλότερο lr). Αυτό υποδηλώνει ότι ο κύριος περιοριστικός παράγοντας είναι το compute budget (εποχές x δείγματα), όχι η χωρητικότητα μοντέλου.

(β) Επίδραση πλήθους κλάσεων: Η απόδοση mIoU εξαρτάται κρίσιμα από το πλήθος κλάσεων. 21 κλάσεις SBD με 600 δείγματα δίνουν mIoU ~4%, ενώ 3 κλάσεις Pet με 1200 δείγματα δίνουν mIoU ~65%. Η pixel accuracy αποτελεί παραπλανητική μετρική όταν υπάρχει ισχυρή ανισορροπία κλάσεων (SBD: PA=70% παρά mIoU=4%).

(γ) CNN vs ViT: Στη βάση δεδομένων μικρής κλίμακας (5000 δείγματα), το SmallCNN υπερτερεί κατά ~19 ποσοστιαίες μονάδες και εκπαιδεύεται ~4x πιο γρήγορα. Το inductive bias τοπικής συνδεσιμότητας και μεταθετικής αναλλοίωτης ισοδυναμίας που ενσωματώνουν οι CNN αρχιτεκτονικές αποδεικνύεται αποφασιστικό πλεονέκτημα έναντι των ViT που μαθαίνουν αυτές τις ιδιότητες data-driven.

(δ) Οι αρχιτεκτονικές (U-Net, SmallCNN, TinyViT) λειτουργούν ορθά και αποδίδουν αναμενόμενα αποτελέσματα για τις δεδομένες συνθήκες CPU training. Κύριοι παράγοντες που θα βελτίωναν περαιτέρω την απόδοση είναι: GPU εκπαίδευση, μεγαλύτερα υποσύνολα δεδομένων, και αύξηση μεγέθους εικόνας (256x256 αντί 128x128 για τμηματοποίηση).